

İstanbul Toplu Ulaşım (İETT) Saatlik Yolcu Analizi

Veri Bilimi Dönem Projesi
Gürkan Kılınç • 1306240134 • Bireysel

1. Problem Tanımı

Bu çalışma, İstanbul'daki otobüs (karayolu) toplu ulaşım talebinin zaman (saat, gün, mevsim) ve mekân (ilçe, hat) boyutlarında nasıl değiştiğini anlamayı amaçlar. Saatlik İstanbulkart işlem verisi üzerinden, talebin ne zaman ve nerede yoğunlaştığı keşfedilir ve saatlik yolcu sayısı zaman özelliklerinden tahmin edilmeye çalışılır. Üç temel araştırma sorusu şunlardır: (1) Gün içinde pik saatler nedir ve hafta içi/sonu nasıl değişir? (2) Yolcu sayısında mevsimsel bir değişim var mı? (3) Toplam talebi az sayıda hat mı taşıyor? Bu sorulara ilçe ve ücret tipi kırılımı ile iki ek analiz eklenmiştir.

2. Veri Seti ve Kaynağı

Kaynak: İBB Açık Veri Portalı — Saatlik Toplu Ulaşım Veri Seti.

Sağlayıcı: BELBİM A.Ş. (İstanbulkart işletmecisi).

Lisans: İstanbul Büyükşehir Belediyesi Açık Veri Lisansı.

Bağlantı: data.ibb.gov.tr/dataset/hourly-public-transport-data-set

Ham veri seti 63.555.260 satır ve 14 sütundan oluşur ve bellekte yaklaşık 6,6 GB yer kaplar. Bu, tipik bir öğrenci veri setinin çok üzerinde, gerçek ölçekli bir veridir. Her satır; tarih, saat (transition_hour), ulaşım türü, hat, ilçe, ücret/kart tipi ve yolcu/yolculuk sayısı bilgisini taşır. Çalışmada 2023 yılından mevsimleri temsil eden dört ay (Ocak, Nisan, Temmuz, Ekim) ve yalnızca otobüs (transport_type_id = 1) türü kullanılmıştır.

3. Yöntem

Veri toplama: Aylık CSV dosyaları bir Python betiği (download_data.py) ile portaldan indirilip tek dosyada birleştirildi.

Veri mühendisliği kararı: 63,5 milyon satırın tamamı belleğe sığmadığından, önce otobüs satırları filtrelendi (41.240.679 satır), ardından %10 tabakasız örnekleme yapıldı (4.124.068 satır). Bu, 'önce küçült, sonra işle' ilkesinin uygulanmasıdır.

Temizleme: Tarih ve saat ayrı sütunlarda olduğundan saat bilgisi transition_hour'dan alındı; tarihten saat, haftanın günü, hafta sonu ve ay türetildi. 2023 resmî tatilleri elle işaretlendi (tatil_mi). Analizde kullanılan sütunlarda eksik değer yoktur; yüksek eksikliğe sahip sütunlar (station_poi_desc_cd, town) ya kullanılmadı ya da eksikleri çıkarıldı. Aykırı değerler IQR ile tespit edildi ancak silinmedi, yalnızca işaretlendi — çünkü yüksek değerler gerçek pik saatleri temsil eder.

Modelleme: Saatlik toplam yolcu, zaman özelliklerinden (saat, gün, ay, hafta sonu, tatil) tahmin edildi. Veri bir zaman serisi olduğundan rastgele bölme yerine zamansal ayırım kullanıldı: ilk üç ay eğitim, son ay (Ekim) test. Bu, gelecekte geçmişe bilgi sızmasını (data leakage) önler. Modelin değer kattığını göstermek için naif bir baseline (her saatin ortalaması) ile karşılaştırıldı. İkinci teknik olarak hatlar saatlik profil şekline göre KMeans ile kümelendi.

Aşama	Değer
Ham satır sayısı	63.555.260
Otobüs satırı (filtre sonrası)	41.240.679
Örnekleme (%10)	4.124.068
Tatil günü kaydı	198.747
IQR üst sınırı / sınır üstü kayıt	14 / 588.006


4. Bulgular

4.1 Pik saatler (Soru 1)

Saatlik ortalama yolcu profili belirgin bir çift tepe yapısı gösterir: en yüksek nokta sabah 07:00 civarındadır; akşam ise 17:00–18:00 arası ikinci bir tepe oluşur. Bu, klasik işe gidiş-dönüş (commute) örüntüsüyle uyumludur. Hafta sonu bu keskin tepeler silinir ve talep gün içine daha düz yayılır — yani pik saatleri iş/okul rutini sürükler.

4.2 Mevsimsellik (Soru 2)

Aylık toplam yolcudaki net bir mevsimsel iz vardır: Temmuz (yaz/okul tatili) 9,59 milyon ile en düşük aydır; Ekim 12,45 milyon ile en yüksektir. Yaz düşüşü, eğitim takviminin toplu taşıma talebini güçlü biçimde etkilediğini gösterir. Resmî tatil günlerinin saatlik profili de hafta sonuna benzer (düz) çıkmıştır; bu, modelde kullanılan tatil_mi özelliğinin anlamlı olduğunu doğrular.




4.3 Hat yoğunluğu — Pareto (Soru 3)

Talep az sayıda hatla yoğunlaşmıştır: hatların yalnızca ilk %20'si toplam yolcunun %72,8'ini taşır. Bu güçlü bir Pareto (80-20'ye yakın) etkisidir ve şebekede az sayıda yoğun koridorun belirleyici olduğunu gösterir; bu da hat planlaması ve kaynak tahsisi için kritik bir bulgudur.


4.4 İlçe bazlı talep (Soru 4)

İlçe kırılımında Bakırköy 23,4 milyon ile diğer tüm ilçelerin çok üzerinde, açık ara liderdir; onu Küçükçekmece (2,77M) ve Sarıyer (1,71M) izler. Bakırköy'ün bu denli baskın olması, büyük bir aktarma/terminal merkezi olmasından ya da biniş ilçesinin kodlanma biçiminden kaynaklanıyor olabilir; bu nedenle tek başına yorumlanırken dikkatli olunmalıdır. Yine de talebin Pareto bulgusuna paralel biçimde belirli merkezlerde toplandığı açıktır.




4.5 Ücret tipi dağılımı (Soru 5)

Yolcuların büyük kısmı iki ana türde toplanır: İndirimli Abonman (~%33) ve Tam Kontur (~%31) birlikte talebin yaklaşık üçte ikisini oluşturur. Ücretsiz binişler (~%15) da kayda değer bir paya sahiptir. Bu dağılım, yolcu profilinin sosyo-ekonomik bir göstergesidir (öğrenci/abonman ağırlığı).



4.6 Modelleme sonuçları

Naif baseline modeli 27.762 MAE verirken, RandomForest regresyonu test ayında (Ekim) $R^2 = 0,750$ ve $MAE = 19.155$ elde etmiştir; bu, baseline'a göre %31 iyileşme demektir. Yani model, basit saat ortalamasının ötesinde gerçek bir açıklayıcı güce sahiptir. Özellik önemlerinde saat (0,66) açık ara en belirleyici değişkendir; onu tatil (0,21) izler. Bu, talebin öncelikle günün saatine, ikincil olarak takvim etkisine (tatil) bağlı olduğunu gösterir.



4.7 Hat kümeleme (ikinci model)

Otobüs hatları saatlik profil şekillerine göre üç kümeye ayrıldı (111 / 431 / 327 hat). Kümeler yorumlanabilir tipler ortaya çıkardı: sabah+akşam çift tepeli işe-gidiş hatları, gün boyu dengeli gün-içi hatlar ve daha düşük/yayvan profilli hatlar. Bu, otobüs ağının homojen olmadığını ve farklı işlevsel hat tiplerinden oluştuğunu gösterir.

5. Sınırlamalar

- Yalnızca 2023'ün 4 ayı ve tek ulaşım türü (otobüs) analiz edildi; tüm yıl ve diğer türler (raylı, deniz) kapsam dışıdır.
- Bellek nedeniyle %10 örnekleme yapıldı; mutlak toplamalar gerçeğin yaklaşık %10'u ölçeğindedir (oran ve desenler korunur, mutlak sayılar değil).
- Zamansal ayırım uygulandı ancak tek aylık test penceresi dardır.
- Hava durumu, özel etkinlikler gibi dış değişkenler modele dahil edilmedi.
- İlçe (town) alanındaki Bakırköy aşırı değeri, kodlama kaynaklı olabileceğinden ayrıca doğrulanmalıdır.

6. Öğrenilenler (vibe coding öz-değerlendirme)

Proje, bir yapay zekâ kodlama asistanı birincil geliştirme ortağı olarak kullanılarak geliştirildi. Bu süreçte en değerli ders, üretilen kodu körü körüne kabul etmemek oldu. İki kritik müdahale buna örnektir: (1) Asistanın ilk kurduğu kodda saat bilgisi yanlışlıkla tarih sütunundan türetiliyordu ve tüm saatler 0 çıkıyordu; gerçek saatin ayrı bir sütunda (transition_hour) olduğu fark edilip düzeltildi. (2) İlk modelleme rastgele train/test bölmesi kullanıyordu; zaman serisi için bunun veri sızıntısı yaratacağı görülüp zamansal ayırma geçildi. Ayrıca 63,5 milyon satırlık veride bellek hatasıyla karşılaşılması, filtreleme ve örnekleme gibi veri mühendisliği kararlarının zorunluluğunu öğretti. Sürecin en çok zaman alan kısmı kod yazmak değil, çıktıları doğrulamak ve gerçek sütun adlarıyla eşlemek oldu.

Kaynak kod, notebook ve prompt günlüğü: github.com/gurkankilinc/Veri-Bilimi-Final-Projesi