

İstanbul Otobüs Ağı Saatlik Yolcu Analizi

Veri Bilimi Dönem Projesi | 2024-2025 Bahar Dönemi
Gürkan Kılınç | 1306240134 | Bireysel

1. Amaç ve Hedefler

Bu çalışmanın temel amacı, İstanbul'da otobüs (karayolu) toplu ulaşım talebini saatlik granüleritede anlamak ve zaman tabanlı özelliklerle tahmin etmektir. Belirlenen hedefler şunlardır:

1. Saatlik talep profilini saat, gün ve mevsim boyutlarında karakterize etmek.
2. Az sayıda hattın toplam talebi ne ölçüde taşıdığını (Pareto etkisi) ölçmek.
3. Yolcu tabanının ücret tipi ve ilçe kırılımıyla demografik ve coğrafi yapısını ortaya koymak.
4. Zaman özelliklerinden saatlik yolcu sayısını tahmin eden, gerekçeli ve doğrulanmış bir model geliştirmek.
5. Elde edilen bulguları somut işletme ve planlama önerilerine dönüştürmek.

Çalışma, uçtan uca bir veri bilimi iş akışını (toplama → temizleme → EDA → modelleme → yorum) gerçek ölçekli İstanbul verisi üzerinde uygulamaktadır.

2. Veri Seti ve Kaynağı

- Veri seti: Saatlik Toplu Ulaşım Veri Seti — BELBİM A.Ş. (İstanbulkart işletmecisi)
- Portal: data.ibb.gov.tr/dataset/hourly-public-transport-data-set
- Lisans: İstanbul Büyükşehir Belediyesi Açık Veri Lisansı

Ham veri seti 63.555.260 satır ve 14 sütundan oluşur; bellekte 6,6 GB yer kaplar. Çalışmada 2023'ten mevsimleri temsil eden dört ay (Ocak, Nisan, Temmuz, Ekim) ve yalnızca otobüs modu (transport_type_id = 1) kullanılmıştır.

Yolcu sayısı dağılımı aşırı sağa çarpıktır: medyan 2, ortalama $\approx 12,6$, maks 5.719. Kayıtların büyük çoğunluğu küçük değerlerde toplanır; dağılım logaritmik ölçeğe incelenmiştir.

3. Yöntem

- Veri toplama: Aylık CSV'ler bir Python betiği (download_data.py) ile portaldan indirilip tek dosyada birleştirildi.
- Bellek yönetimi: 63,5M satır RAM'e sığmadığından otobüs satırları filtrelendi (41.240.679), ardından %25 örnekleme yapıldı (10.310.170 satır).
- Temizleme: Saat bilgisi ayrı sütundan (transition_hour) alındı; saat, gün, hafta sonu, ay türetildi; 2023 resmî tatilleri işaretlendi. Aykırı değerler IQR ile tespit edildi ancak silinmedi — yüksek değerler gerçek pik saatlerini temsil eder.
- Veri kalitesi düzeltilmesi: town sütununda GPS okuma hatası kaynaklı sistematik atama sorunu tespit edildi; belirli hatların tüm kayıtlarının tek ilçeye atandığı görüldü. Veri güdümlü oran eşiği mantığıyla temizlik uygulandı.
- EDA: Çizgi, histogram (log ölçek), kutu, ısı haritası, bar ve dağılım grafiği olmak üzere altı görselleştirme türü kullanıldı.
- Modelleme: Zamansal ayırım (son ay test), beş model karşılaştırması, birini-dışarıda-bırak çapraz doğrulama (GroupKFold), hafif hiperparametre taraması ve artık analizi uygulandı.
- İkinci model: Hatlar saatlik profil şekline göre KMeans ile üç kümeye ayrıldı.

Aşama	Değer
Ham satır	63.555.260
Otobüs satırı (filtre)	41.240.679
Örnekleme (%25)	10.310.170
Tatil günü kaydı	198.747
IQR üst sınır / sınır üstü kayıt	14 / 588.006


4. Bulgular

4.1 Gün-içi pik saatler ve hafta içi / hafta sonu farkı

Hafta içi saatlik talep profili sabah 07:00-08:00 ve akşam 17:00-18:00 saatlerinde belirgin çift tepe oluşturur; bu örüntü çalışan nüfusun işe gidiş-dönüş davranışıyla birebir örtüşür. Hafta sonu bu tepeler ortadan kalkar ve talep gün içine daha düz yayılır. Bulgu, frekans planlamasının hafta içi/hafta sonu için zorunlu olarak farklılaştırılması gerektiğine işaret eder.

4.2 Mevsimsellik ve tatil etkisi

Aylık toplam yolcudaki net bir mevsimsel iz vardır: Temmuz (okul tatili) 9,59 milyon ile en düşük, Ekim 12,45 milyon ile en yüksek aydır. Bu düşüş; öğrenci abonemalarının pasifleşmesi ve kurumsal çalışmaların yavaşlamasıyla açıklanır. Resmî tatil günlerinin profili de hafta sonuna benzer biçimde düzleşir; bu, modelde kullanılan tatil_mi özelliğinin gerekliliğini doğrular.



Şekil 1. Aylara göre toplam yolcu — Temmuz'da okul tatili kaynaklı belirgin düşüş.

4.3 Pareto etkisi — az sayıda hat, büyük çoğunluk


Hatların yalnızca ilk %20'si toplam yolcunun %72,8'ini taşır. Bu güçlü asimetrik dağılım, kaynak planlamasında az sayıda yoğun koridora odaklanmanın potansiyel etkinliğini kanıtlar. Uzun vadede bu yoğun koridorlar metrobüs/raylı gibi yüksek kapasiteli sistemlere aday olarak değerlendirilebilir.

4.4 Coğrafi yoğunlaşma

Veri kalitesi düzeltilmesinin ardından ilçe bazlı analiz, yolcu talebinin birden fazla metropoliten eksende dağıldığını ortaya koyar. Başlangıçta tek bir ilçenin (BAKIRKOY) aşırı baskın çıkması, GPS'in okunamadığı durumlarda sistemin tetiklediği bir fallback mekanizmasından kaynaklanmaktaydı — belirli hat kodlarının kayıtlarının %90'ından fazlası tek ilçeye atanmıştı. Veri güdümlü eşik analiziyle bu hatalar temizlenerek gerçek coğrafi dağılım ortaya konulmuştur. Düzeltilmiş analiz, Pareto bulgusunun mekânsal karşılığını ve hat bazlı yoğunlaşmanın coğrafi düzlemde de gözlemlendiğini doğrulamaktadır.

4.5 Ücret tipi dağılımı

Yolcuların yaklaşık üçte ikisi İndirimli Abonman (~%33) ve Tam Kontur (~%31) kategorilerinde yoğunlaşır. İndirimli abonmanın baskınlığı düzenli ve öğrenci yolcuların tabanı oluşturduğunu; ücretsiz binışler (~%15) ise 65 yaş üstü ve hak sahibi segmentin önemli büyüklüğünü yansıtır. Bu dağılım, ücret politikası ve gelir tahmini için anlamlı bir sosyo-ekonomik göstergedir.




Şekil 2. Ücret tipine göre toplam yolcu — abonman ve kontur baskın.

5. Modelleme

Saatlik toplam yolcu zaman özelliklerinden tahmin etmek için beş yaklaşım karşılaştırılmıştır. Zaman serisi olduğundan rastgele bölme yerine zamansal ayırım uygulanmış (son ay = test), sızıntı önlenmiştir. Doğrusal regresyon (MAE 104.748) naif baseline'ı (69.432) da geride bırakarak, taleple zaman değişkenleri arasındaki ilişkinin doğrusal olmadığını kanıtlamıştır.


Model	R ²	MAE
Gradient Boosting	0,773	45.495
Random Forest (seçilen)	0,754	47.724
Karar Ağacı	0,747	48.261
Baseline (saat ortalaması)	0,515	69.432
Doğrusal Regresyon	0,129	104.748

Gradient Boosting marjinal olarak önde çıksa da, yorumlanabilir özellik önemleri ve daha stabil çapraz doğrulama davranışı nedeniyle Random Forest tercih edilmiştir. Seçilen model baseline'a göre %31,3 daha düşük hata ($R^2 = 0,754$, MAE = 47.724) verir.




Şekil 3. Beş model karşılaştırması — doğrusal modelin zayıflığı, ağaç tabanlı üstünlük.

Modelin tek aya bağılı olmadığını doğrulamak için birini-dışarıda-bırak çapraz doğrulama uygulanmıştır: Ocak 0,893 · Nisan 0,527 · Temmuz 0,863 · Ekim 0,750 — ortalama $R^2 = 0,762 \pm 0,143$. Nisan'ın görece düşük skoru, ayın Ramazan Bayramı (21-23 Nisan) ve 23 Nisan tatilleri gibi düzensiz tatil günleri içermesiyle açıklanır; bu da tatil_mi özelliğinin anlamlılığını pekiştirir. Artık analizi, hataların sıfır etrafında desensiz dağıldığını ve yapısal bir yanlılık bulunmadığını göstermiştir.



Şekil 4. Çapraz doğrulama — Nisan hariç yüksek ve tutarlı.

Özellik önemlerinde saat (0,66) açık ara en belirleyici değişkendir; onu tatil (0,21) izler. Bu hiyerarşi, talebin öncelikle günün saatine, ikincil olarak takvim etkisine kilitli olduğunu gösterir.



Şekil 5. Özellik önemleri — saat baskın, tatil ikincil modülatör.

Hat kümeleme modeli (KMeans, k=3) üç işlevsel tip ortaya çıkardı: sabah+akşam çift tepeli işe-gidiş hatları, gün boyu dengeli gün-içi hatlar ve düşük/yayvan profilli hatlar. Pareto, coğrafi yoğunlaşma ve kümeleme birlikte tek bir resim çizer: İstanbul otobüs ağı az sayıda yoğun koridor ve işlevsel olarak heterojen hat segmentleri etrafında örgütlenmiş asimmetrik bir yapıya sahiptir.

6. Sonuç ve Öneriler

- Pik saat takviyesi: 07:00 ve 17-18:00 tepelerinde, özellikle talebin %72,8'ini taşıyan ilk %20'lik hatlarda sefer sıklığı artırılmalı; pik dışında frekans düşürülerek kaynak dengelenmelidir.
- Yoğun koridorlara öncelik: Pareto nedeniyle yatırım ve araç tahsisi bu az sayıdaki hatta yönlendirilmeli; uzun vadede metrobüs/raylı aday değerlendirmesi yapılmalıdır.
- Mevsimsel çizelgeleme: Temmuz'da talep düştüğünden yaz aylarında sefer frekansı azaltılmalı; kaynak yüksek talep dönemine (Ekim) kaydırılmalıdır.

- Hafta sonuna ayrı çizelge: Çift tepe kaybolan hafta sonu için gün boyu dengeli bir plan kullanılmalıdır.
- Talep tahmininin karar desteğine dönüştürülmesi: Model ($R^2 \approx 0,76$), gün-öncesi sefer planlaması ve sürücü vardiya tahmininde karar-destek aracı olabilir.
- Hat tipine göre farklı strateji: Kümeleme sonucu; işe-gidiş hatlarında pik takviyesi, gün-içi hatlarda dengeli frekans önceliklendirilmeli, düşük-yoğunluklu hatlarda minimum hizmet standartları belirlenmelidir.
- Veri kalitesi izleme altyapısı: town sütunundaki fallback mekanizması kaynaklı sistematik atama hataları, GPS altyapısının güçlendirilmesini ve operasyonel veri kalitesi izleme süreçlerinin kurulmasını gerektirmektedir.

7. Sınırlamalar

- 2023'ün yalnızca 4 ayı ve tek mod (otobüs) kullanıldı; raylı sistem ve deniz ulaşımı kapsam dışıdır.
- %25 örnekleme uygulandığından mutlak toplamlar gerçeğin %25'i ölçeğindedir; oran ve desenler korunur, mutlak sayılar değil.
- Çapraz doğrulama 4 aylık veri üzerinde yapıldı; yıl geneli örüntüler tam temsil edilmez.
- Hava durumu, büyük kentsel etkinlikler ve yol kapanmaları modele dahil edilmedi.
- town sütunundaki GPS fallback sorunu büyük ölçüde giderilmiş olmakla birlikte, resmi GPS referans verisi olmaksızın tam bütünlük garanti edilemez.

8. Öğrenilenler — Vibe Coding Öz-Değerlendirme

Proje, yapay zekâ kodlama asistanı birincil geliştirme ortağı olarak kullanılarak yürütülmüştür. En değerli ders, üretilen kodu ve yorumu körü körüne kabul etmemek olmuştur. Asistanın önerisinden sapılan üç kritik karar:

- Veri sızıntısı: Rastgele bölme yerine zamansal ayrıma geçildi — zaman serisinde gelecekte geçmişe bilgi sızması önlendi.
- Model seçimi: Tek model yerine beş model karşılaştırması eklendi; seçim ampirik kanıta dayandırıldı.
- Veri kalitesi — Bakırköy aşırı değeri: Başlangıçta varsayılan 'büyük terminal etkisi' açıklaması, hat bazlı oran analizi yapıldığında desteklenmedi. GPS fallback mekanizması tespit edilerek temizlik bloğu veri güdümlü bir mantıkla yeniden tasarlandı.

Sürecin en çok zaman alan kısmı kod yazmak değil, çıktıları doğrulamaktı. Görsel denetim vazgeçilmez; yüksek R^2 model doğruluğunu garantilemez, veri kalitesini doğrulamaz.

Kaynak kod, notebook ve prompt günlüğü: github.com/gurkankilinc/Veri-Bilimi-Final-Projesi