

İstanbul Toplu Ulaşım (İETT) Saatlik Yolcu Analizi

Veri Bilimi Dönem Projesi
Gürkan Kılınç | 1306240134 | Bireysel | Haziran 2026

1. Problem Tanımı

Bu çalışma, İstanbul'daki otobüs (karayolu) toplu ulaşım talebinin zaman (saat, gün, mevsim) ve mekân (ilçe, hat) boyutlarında nasıl değiştiğini anlamayı amaçlar. Saatlik İstanbulkart işlem verisi üzerinden talebin ne zaman ve nerede yoğunlaştığı keşfedilmiş; ayrıca saatlik yolcu sayısı zaman özelliklerinden tahmin edilmiştir. Tanımlanan üç temel araştırma sorusu:

1. Gün içinde pik saatler nedir; hafta içi ve hafta sonu profili nasıl değişir?
2. Yolcu sayısında mevsimsel bir değişim var mı (örn. yaz tatili etkisi)?
3. Toplam talebi az sayıda hat mı taşıyor (Pareto / 80-20 etkisi)?

Bu üç soruya ek olarak, talebin ilçe ve ücret tipi kısıtları iki ek analizle incelenmiştir.

2. Veri Seti ve Kaynağı

- Veri seti: Saatlik Toplu Ulaşım Veri Seti
- Sağlayıcı: BELBİM A.Ş. (İstanbulkart işletmecisi)
- Lisans: İstanbul Büyükşehir Belediyesi Açık Veri Lisansı
- Portal: data.ibb.gov.tr/dataset/hourly-public-transport-data-set

Ham veri seti 63.555.260 satır ve 14 sütundan oluşur ve bellekte yaklaşık 6,6 GB yer kaplar; bu, tipik bir öğrenci veri setinin çok üzerinde, gerçek ölçekli bir veridir. Çalışmada 2023 yılından dört ay (Ocak, Nisan, Temmuz, Ekim) ve yalnızca otobüs (`transport_type_id = 1`) türü kullanılmıştır.

Yolcu sayısı dağılımı aşırı sağa çarpıktır (medyan 2, ortalama $\approx 12,6$, en yüksek 5.719): kayıtların çoğu küçük değerlerde toplanır, az sayıda kayıt çok yüksektir. Bu nedenle dağılım logaritmik ölçekte incelenmiştir.

3. Yöntem

- Veri toplama: Aylık CSV dosyaları bir Python betiği (`download_data.py`) ile portaldan indirilip tek dosyada birleştirildi.
- Veri mühendisliği kararı: 63,5 milyon satır belleğe sığmadığından, önce otobüs satırları filtrelendi (41.240.679), ardından %10 örnekleme yapıldı (4.124.068 satır).
- Temizleme: Saat bilgisi ayrı sütunda olduğundan `transition_hour`'dan alındı; saat, gün, hafta sonu ve ay türetildi; 2023 resmî tatilleri işaretlendi. Kullanılan sütunlarda eksik değer yoktur. Aykırı değerler IQR ile tespit edildi ancak silinmedi, yalnızca işaretlendi.
- Keşifsel analiz: Altı farklı görselleştirme türü kullanıldı — çizgi, histogram, kutu, ısı haritası, bar ve dağılım grafiği.
- Modelleme: Saatlik toplam yolcu zaman özelliklerinden tahmin edildi; zamansal ayrım, beş model karşılaştırması, birini-dışarıda-bırak çapraz doğrulama, GroupKFold

hiperparametre ayarı ve artık analizi uygulandı.

- İkinci model: Hatlar saatlik profil şekline göre KMeans ile kümelendi.

Aşama	Değer
Ham satır sayısı	63.555.260
Otobüs satırı (filtre sonrası)	41.240.679
Örnekleme (%10)	4.124.068
Tatil günü kaydı	198.747
IQR üst sınırı / sınır üstü kayıt	14 / 588.006


4. Bulgular

4.1 Pik saatler — Soru 1

Saatlik ortalama yolcu profili belirgin bir çift tepe gösterir: en yüksek nokta sabah 07:00 civarındadır, akşam 17:00–18:00 arası ikinci bir tepe oluşur — bu klasik işe gidiş-dönüş örüntüsüyle uyumludur. Hafta sonu bu keskin tepeler silinir ve talep gün içine daha düz yayılır; yani pik saatleri iş/okul rutini sürükler.

4.2 Mevsimsellik ve tatil etkisi — Soru 2

Aylık toplamda net bir mevsimsel iz vardır: Temmuz (yaz/okul tatili) 9,59 milyon ile en düşük, Ekim 12,45 milyon ile en yüksek aydır. Ayrıca resmî tatil günlerinin saatlik profili hafta sonuna benzer biçimde düz çıkmıştır. Her iki bulgu da talebin büyük ölçüde eğitim ve çalışma takvimine bağlı olduğunu doğrular.




Şekil 1. Aylara göre toplam yolcu — yaz ayında belirgin düşüş.

4.3 Hat yoğunluğu — Soru 3 (Pareto)

Talep az sayıda hatta yoğunlaşır: hatların yalnızca ilk %20'si toplam yolcunun %72,8'ini taşır. Bu güçlü bir Pareto etkisidir ve şebekede az sayıda yoğun koridorun belirleyici olduğunu gösterir.

4.4 İlçe bazlı talep — Soru 4


Bakırköy 24,0 milyon (örneklem) ile diğer tüm ilçelerin çok üzerinde, açık ara liderdir. İncelendiğinde Bakırköy'de 563 farklı hat işlediği ve en yoğun 3 hattın ilçe talebinin yalnızca %6,9'unu oluşturduğu görülür. Yani yoğunluk tek/birkaç dev hattan değil, çok sayıda güzergâhın bu noktadan geçmesinden kaynaklanır; bu da Bakırköy'ün büyük bir aktarma/terminal merkezi olduğunu doğrular.



Şekil 2. En yüksek yolcu üreten ilçeler — Bakırköy açık ara önde.

4.5 Ücret tipi dağılımı — Soru 5


Talep iki ana türde yoğunlaşır: İndirimli Abonman (~%33) ve Tam Kontur (~%31) birlikte yaklaşık üçte ikiyi oluşturur. İndirimli abonmanın baskınlığı, yolcuların önemli bölümünün öğrenci/düzenli (aylık kart) yolcu olduğunu düşündürür; ücretsiz binışler (~%15) ise 65 yaş üstü ve hak sahibi gruplara işaret eder.



Şekil 3. Ücret tipine göre toplam yolcu (ilk 6).


4.6 Modelleme, karşılaştırma ve doğrulama

Model seçimi hisle değil, kanıtla yapılmıştır: aynı zamansal ayırmada beş yaklaşım karşılaştırılmıştır. Doğrusal regresyon (MAE 41.843) naif baseline'dan (27.762) bile kötü çıkarak, talep ile zaman değişkenleri arasındaki ilişkinin doğrusal olmadığını kanıtlamıştır. Ağaç tabanlı modeller belirgin biçimde öne geçmiştir: Gradient Boosting 18.545, Random Forest 19.155, Karar Ağacı 19.456. Gradient Boosting çok küçük bir farkla önde olsa da, yorumlanabilir özellik önemleri sağladığı ve fark ihmal edilebilir olduğu için Random Forest ana model olarak korunmuştur.




Şekil 4. Beş modelin test MAE karşılaştırması — doğrusal model en zayıf.

Seçilen Random Forest, baseline'a göre %31 daha düşük hata verir ($R^2 = 0,750$, MAE = 19.155). GroupKFold hiperparametre taraması varsayılanına göre yalnızca küçük bir iyileşme sağlamıştır (R^2 0,750 $\rightarrow$ 0,759), bu da varsayılan ayarların yeterli olduğunu doğrular. Birini-dışarıda-bırak çapraz doğrulamada her ay sırayla test edilmiştir: Ocak 0,893; Nisan 0,527; Temmuz 0,863; Ekim 0,750 — ortalama $R^2 = 0,758 \pm 0,144$. Nisan'ın görece düşük çıkması, ayın Ramazan Bayramı (21–23 Nisan) ve 23 Nisan gibi düzensiz tatil günleri içermesiyle açıklanır — genel zaman özellikleriyle tam yakalanamayan bu sapmalar, tatil_mi özelliğinin gerekliliğini de pekiştirir.



Şekil 5. Her ay sırayla test edildiğinde R^2 — Nisan hariç yüksek ve tutarlı.

Özellik önemlerinde saat (0,66) açık ara en belirleyici değişkendir; onu tatil (0,21) izler. Bunun nedeni, talebin iş ve okul başlangıç-bitiş saatlerine kilitlenmiş olması, takvim etkisinin (tatil) ise bu örüntüyü ikincil olarak modüle etmesidir. Son olarak artık analizi, hataların sıfır etrafında ve belirgin bir sistematik sapma olmadan dağıldığını göstererek modelin yapısal bir yanlılık taşımadığını doğrulamıştır.



Şekil 6. Özellik önemleri — saat baskın belirleyici.

4.7 Hat kümeleme — İkinci Model

Otobüs hatları saatlik profil şekline göre üç kümeye ayrıldı (111 / 431 / 327 hat): sabah+akşam çift tepeli işe-gidiş hatları, gün boyu dengeli gün-içi hatlar ve daha düşük/yayvan profilli hatlar.

Sentez: Pareto (talep az sayıda hatta), Bakırköy (çok sayıda hattın tek noktada buluşması) ve kümeleme (farklı hat tipleri) birlikte tek bir resmi anlatır: İstanbul otobüs ağı az sayıda yoğun koridor ve büyük aktarma düğümleri etrafında örgütlenmiş, işlevsel olarak heterojen bir yapıdır.

5. Sonuç ve Öneriler

Analizin ortaya koyduğu örüntüler, aşağıdaki somut işletme ve planlama önerilerine dönüştürülebilir:

- **Pik saat takviyesi:** Sabah 07:00 ve akşam 17:00–18:00 çift tepelerinde, özellikle yolcunun %72,8'ini taşıyan ilk %20'lik yoğun hatlarda sefer sıklığı artırılmalı; pik dışı saatlerde frekans düşürülerek kaynak dengelenmelidir.
- **Yoğun koridorlara öncelik:** Pareto etkisi nedeniyle yatırım ve araç tahsisi öncelikle bu az sayıdaki yoğun koridora yönlendirilmeli; uzun vadede bu hatlar metrobüs/raylı gibi yüksek kapasiteli sistemlere aday değerlendirilmelidir.
- **Mevsimsel çizelgeleme:** Temmuz'da talep belirgin düştüğünden yaz aylarında sefer frekansı kontrollü azaltılmalı; tasarruf edilen kaynak bakıma ve talebin zirve yaptığı Ekim gibi aylara kaydırılmalıdır.
- **Hafta sonuna ayrı çizelge:** Hafta sonu çift tepe kaybolup talep güne yayıldığından, hafta içi çizelgesi olduğu gibi uygulanmamalı; gün boyu daha dengeli bir hafta sonu plan kullanılmalıdır.
- **Aktarma düğümlerinin güçlendirilmesi:** 563 hattın geçtiği Bakırköy gibi düğümlerde peron/durak kapasitesi ve aktarma süreleri iyileştirilmeli; aynı analiz Kadıköy, Üsküdar gibi noktalar için de tekrarlanmalıdır.
- **Talep tahmininin karar desteğine dönüştürülmesi:** Model, yalnızca saat/gün/ay/tatil bilgisiyle $R^2 \approx 0,75$ doğruluk verdiği için, gün-öncesi sefer planlaması ve vardiya tahmininde kullanılabilir.
- **Hat tipine göre yönetim:** Kümeleme sonucu ayrıışan işe-gidiş, gün-içi ve düşük-yoğunluk hat tipleri için farklı işletme stratejileri uygulanmalı; işe-gidiş hatlarında pik takviyesi önceliklendirilmelidir.

6. Sınırlamalar

- Yalnızca 2023'ün 4 ayı ve tek ulaşım türü (otobüs) analiz edildi; tüm yıl ve diğer türler kapsam dışıdır.
- %10 örnekleme yapıldığından mutlak toplamalar gerçeğin yaklaşık %10'u ölçeğindedir (oran ve desenler korunur, mutlak sayılar değil).
- Model çapraz doğrulama ve karşılaştırmayla sınandı; yine de yalnızca dört aylık veri kullanıldı.
- Hava durumu, özel etkinlikler ve okul takvimi gibi dış değişkenler modele dahil edilmedi.

7. Öğrenilenler (vibe coding öz-değerlendirme)

Proje, bir yapay zekâ kodlama asistanı birincil geliştirme ortağı olarak kullanılarak geliştirildi. En değerli ders, üretilen kodu ve yorumu körü körüne kabul etmemek oldu. Asistanın çıktısının doğrulanıp düzeltildiği üç kritik an:

- Saat hatası: İlk kodda saat yanlışlıkla tarih sütunundan türetiliyor ve tüm saatler 0 çıkıyordu; gerçek saatin ayrı sütunda (transition_hour) olduğu fark edilip düzeltildi.
- Veri sızıntısı: İlk model rastgele train/test bölmesi kullanıyordu; zaman serisi için bunun sızıntı yaratacağı görülüp zamansal ayrıma ve çapraz doğrulamaya geçildi.
- Bakırköy yorumu: 'Az sayıda yoğun hat' varsayımı yapılmıştı; veri incelendiğinde tersi (563 hattın katkısı) görülüp yorum gerçeğe göre düzeltildi.

Ayrıca 63,5 milyon satırda bellek hatasıyla karşılaşılması, filtreleme ve örnekleme gibi veri mühendisliği kararlarının zorunluluğunu öğretti. Sürecin en çok zaman alan kısmı kod yazmak değil, çıktıları doğrulamaktı.

Kaynak kod, çalışır notebook ve prompt günlüğü: github.com/gurkankilinc/Veri-Bilimi-Final-Projesi