

İstanbul Toplu Ulaşım (İETT) Saatlik Yolcu Analizi

Veri Bilimi Dönem Projesi

Gürkan Kılınç | 1306240134 | Bireysel | Haziran 2026

1. Problem Tanımı

Bu çalışma, İstanbul'daki otobüs (karayolu) toplu ulaşım talebinin zaman (saat, gün, mevsim) ve mekân (ilçe, hat) boyutlarında nasıl değiştiğini anlamayı amaçlar. Saatlik İstanbulkart işlem verisi üzerinden talebin ne zaman ve nerede yoğunlaştığı keşfedilmiş; ayrıca saatlik yolcu sayısı zaman özelliklerinden tahmin edilmiştir. Tanımlanan üç temel araştırma sorusu:

1. Gün içinde pik saatler nedir; hafta içi ve hafta sonu profili nasıl değişir?
2. Yolcu sayısında mevsimsel bir değişim var mı (örn. yaz tatili etkisi)?
3. Toplam talebi az sayıda hat mı taşıyor (Pareto / 80-20 etkisi)?

Bu üç soruya ek olarak, talebin ilçe ve ücret tipi kırılımı iki ek analizle incelenmiştir.

2. Veri Seti ve Kaynağı

- Veri seti: Saatlik Toplu Ulaşım Veri Seti
- Sağlayıcı: BELBİM A.Ş. (İstanbulkart işletmecisi)
- Lisans: İstanbul Büyükşehir Belediyesi Açık Veri Lisansı
- Portal: data.ibb.gov.tr/dataset/hourly-public-transport-data-set

Ham veri seti 63.555.260 satır ve 14 sütundan oluşur ve bellekte yaklaşık 6,6 GB yer kaplar; bu, tipik bir öğrenci veri setinin çok üzerinde, gerçek ölçekli bir veridir. Çalışmada 2023 yılından mevsimleri temsil eden dört ay (Ocak, Nisan, Temmuz, Ekim) ve yalnızca otobüs (transport_type_id = 1) türü kullanılmıştır.

Yolcu sayısı dağılımı aşırı sağa çarpıktır (medyan 2, ortalama $\approx 12,6$, en yüksek 5.719): kayıtların büyük çoğunluğu küçük değerlerde toplanır, az sayıda kayıt çok yüksektir. Bu nedenle dağılım logaritmik ölekte incelenmiştir.

3. Yöntem

- Veri toplama: Aylık CSV dosyaları bir Python betiği (download_data.py) ile portaldan indirilip tek dosyada birleştirildi.
- Veri mühendisliği kararı: 63,5 milyon satır belleğe sığmadığından, önce otobüs satırları filtrelendi (41.240.679), ardından %10 örnekleme yapıldı (4.124.068 satır) — yani 'önce küçült, sonra işle' ilkesi uygulandı.
- Temizleme: Saat bilgisi ayrı sütunda olduğundan transition_hour'dan alındı; saat, gün, hafta sonu ve ay türetildi; 2023 resmî tatilleri işaretlendi. Kullanılan sütunlarda eksik değer yoktur. Aykırı değerler IQR ile tespit edildi ancak silinmedi, yalnızca işaretlendi (yüksek değerler gerçek pik saatleri temsil eder).
- Keşifsel analiz: Altı farklı görselleştirme türü kullanıldı — çizgi, histogram, kutu, ısı haritası, bar ve dağılım (scatter) grafiği.

- Modelleme: Saatlik toplam yolcu, zaman özelliklerinden tahmin edildi. Zaman serisi olduğundan zamansal ayırım (ilk aylar eğitim, son ay test) kullanıldı, ardından birini-dışarıda-bırak çapraz doğrulama ile dört ayda da sınandı. Modelin değer kattığını göstermek için naif bir baseline ile karşılaştırıldı.
- İkinci model: Hatlar, saatlik talep profillerinin şekline göre KMeans ile kümelendi.

Aşama	Değer
Ham satır sayısı	63.555.260
Otobüs satırı (filtre sonrası)	41.240.679
Örneklem (%10)	4.124.068
Tatil günü kaydı	198.747
IQR üst sınırı / sınır üstü kayıt	14 / 588.006


4. Bulgular

4.1 Pik saatler — Soru 1

Saatlik ortalama yolcu profili belirgin bir çift tepe gösterir: en yüksek nokta sabah 07:00 civarındadır, akşam 17:00-18:00 arası ikinci bir tepe oluşur — bu klasik işe gidiş-dönüş (commute) örüntüsüyle uyumludur. Hafta sonu bu keskin tepeler silinir ve talep gün içine daha düz yayılır; yani pik saatleri iş/okul rutini sürükler.

4.2 Mevsimsellik ve tatil etkisi — Soru 2

Aylık toplamda net bir mevsimsel iz vardır: Temmuz (yaz/okul tatili) 9,59 milyon ile en düşük, Ekim 12,45 milyon ile en yüksek aydır. Ayrıca resmî tatil günlerinin saatlik profili, hafta sonuna benzer biçimde düz çıkmıştır. Her iki bulgu da talebin büyük ölçüde eğitim ve çalışma takvimine bağlı olduğunu, modelde kullanılan tatil_mi özelliğinin anlamlı olduğunu doğrular.




Şekil 1. Aylara göre toplam yolcu — yaz ayında belirgin düşüş.

4.3 Hat yoğunluğu — Soru 3 (Pareto)

Talep az sayıda hatta yoğunlaşır: hatların yalnızca ilk %20'si toplam yolcunun %72,8'ini taşır. Bu güçlü bir Pareto etkisidir ve şebekede az sayıda yoğun koridorun belirleyici olduğunu gösterir; hat planlaması ve kaynak tahsisi için kritik bir bulgudur.

4.4 İlçe bazlı talep — Soru 4


Bakırköy 24,0 milyon (örneklem) ile diğer tüm ilçelerin çok üzerinde, açık ara liderdir. Bu aşırı değer incelendiğinde, Bakırköy'de 563 farklı hat işlediği ve en yoğun 3 hattın ilçe talebinin yalnızca %6,9'unu oluşturduğu görülür. Yani yoğunluk tek/birkaç dev hattan değil, çok sayıda güzergâhın bu noktadan geçmesinden kaynaklanır; bu da Bakırköy'ün büyük bir aktarma/terminal merkezi olduğunu doğrular. Dolayısıyla değer bir hata değil, gerçek bir şebeke düğümüdür.



Şekil 2. En yüksek yolcu üreten ilçeler — Bakırköy açık ara önde.

4.5 Ücret tipi dağılımı — Soru 5

Talep iki ana türde yoğunlaşır: İndirimli Abonman (~%33) ve Tam Kontur (~%31) birlikte yaklaşık üçte ikiyi oluşturur. İndirimli abonmanın baskınlığı, yolcuların önemli bölümünün öğrenci/düzenli (aylık kart) yolcu olduğunu düşündürür; ücretsiz binışler (~%15) ise 65 yaş üstü ve hak sahibi gruplara işaret eder. Bu dağılım, ücret politikası ve gelir tahmini açısından anlamlı bir sosyo-ekonomik göstergedir.




Şekil 3. Ücret tipine göre toplam yolcu (ilk 6).

4.6 Modelleme ve doğrulama


Naif baseline modeli 27.762 MAE verirken, RandomForest regresyonu test ayında (Ekim) $R^2 = 0,750$ ve MAE = 19.155 elde etmiştir; bu, baseline'a göre %31 iyileşme demektir. Modelin tek bir aya bağlı olmadığını doğrulamak için birini-dışarıda-bırak çapraz doğrulama uygulanmıştır:

- Ocak: $R^2 = 0,893$ • Nisan: 0,527 • Temmuz: 0,863 • Ekim: 0,750
- Ortalama $R^2 = 0,758 \pm 0,144$ — dört ayda da pozitif ve tutarlı.

Bu, modelin başarısının rastlantısal olmadığını ve genellenebilir olduğunu kanıtlar. Özellik önemlerinde saat (0,66) açık ara en belirleyici değişkendir; onu tatil (0,21) izler. Yani talep öncelikle günün saatine, ikincil olarak takvim etkisine bağlıdır.



Şekil 4. Her ay sırayla test edildiğinde elde edilen R^2 skorları.



Şekil 5. Modelin özellik önemleri — saat baskın belirleyici.

4.7 Hat kümeleme — İkinci Model

Otobüs hatları, saatlik profil şekline göre üç kümeye ayrıldı (111 / 431 / 327 hat). Kümeler yorumlanabilir tipler ortaya çıkardı: sabah+akşam çift tepeli işe-gidiş hatları, gün boyu dengeli gün-içi hatlar ve daha düşük/yayvan profilli hatlar. Bu, otobüs ağının homojen olmadığını, farklı işlevsel hat tiplerinden oluştuğunu gösterir.

5. Sınırlamalar

- Yalnızca 2023'ün 4 ayı ve tek ulaşım türü (otobüs) analiz edildi; tüm yıl ve diğer türler (raylı, deniz) kapsam dışıdır.
- %10 örnekleme yapıldığından mutlak toplamlar gerçeğin yaklaşık %10'u ölçeğindedir (oran ve desenler korunur, mutlak sayılar değil); grafik başlıklarında bu belirtilmiştir.
- Model birini-dışarıda-bırak çapraz doğrulama ile sınandı; yine de yalnızca dört aylık veri kullanıldığından yıl genelindeki tüm örüntüler temsil edilmez.
- Hava durumu, özel etkinlikler ve okul takvimi gibi dış değişkenler modele dahil edilmedi.

6. Öğrenilenler (vibe coding öz-değerlendirme)

Proje, bir yapay zekâ kodlama asistanı birincil geliştirme ortağı olarak kullanılarak geliştirildi. En değerli ders, üretilen kodu ve yorumu körü körüne kabul etmemek oldu. Asistanın çıktısının doğrulanıp düzeltildiği üç kritik an:

- Saat hatası: İlk kodda saat yanlışlıkla tarih sütunundan türetiliyor ve tüm saatler 0 çıkıyordu; gerçek saatin ayrı sütunda (transition_hour) olduğu fark edilip düzeltildi.
- Veri sızıntısı: İlk model rastgele train/test bölmesi kullanıyordu; zaman serisi için bunun veri sızıntısı yaratacağı görülüp zamansal ayrıma ve çapraz doğrulamaya geçildi.
- Bakırköy yorumu: 'Az sayıda yoğun hat' varsayımı yapılmıştı; veri incelendiğinde tersi (563 hattın katkısı) görülüp yorum gerçeğe göre düzeltildi.

Ayrıca 63,5 milyon satırda bellek hatasıyla karşılaşılması, filtreleme ve örnekleme gibi veri mühendisliği kararlarının zorunluluğunu öğretti. Sürecin en çok zaman alan kısmı kod yazmak değil, çıktıları doğrulamak ve gerçek sütun adlarıyla eşlemek oldu.

Kaynak kod, çalışır notebook ve prompt günlüğü: github.com/gurkankilinc/Veri-Bilimi-Final-Projesi